




Datenanalyse in der Physik

Marcel Lüthi (D-INFK)
Vorlesung am D-Phys der ETH Zürich




Erinnerung: Lineare (logistische) Regression



Modell definiert eine parameterische Funktion $f(x, w)$.

Training: Minimieren der Loss Funktion $L(y, \hat{y}) = L(y, f(x, w))$ nach Parametern w mittels Gradientenabstieg


Erinnerung: Multilayer neural networks



Transformation der Daten mit lernbaren Transformationen
(parametrisiert mit Gewichten w)

Lineare Klassifikation
oder Regression

Erinnerung: Multilayer neural networks



Training: Minimieren der Loss Funktion $L(y, \hat{y}) = L(y, f(x, w))$ nach **allen** Parametern w (in allen Layern) mittels Gradientenabstieg

Weitere Ideen zur Klassifikation

Der Titanic Datensatz

Klassischer Datensatz mit realen Daten zum Titanikunglück

Ziel: Vorhersage ob Passagier überlebt hat.




Siblings
Spouse

Parent/
Children

Ziel-
variable

PassengerId	Survived	Pass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S

K-Nearest Neighbors



Idee: Ein Punkt wird anhand der Mehrheit der K-nächsten Nachbarn klassifiziert


K-Nearest Neighbors

Wichtige Entscheidungen

- Anzahl Nachbarn
- Distanzmass
 - Typischerweise Euklidische Distanz


Gut zu wissen

- Distanzbasiert: Standardisierung der Daten wichtig
- Wahrscheinlichkeit einer Vorhersage kann anhand der Labels der Nachbarn abgeschätzt werden
- Nicht geeignet für hochdimensionale Daten




Einfaches Klassifikationsmodell: Entscheidungsbäume

- Finde Schwellwert eines Attributs (Schnitt entlang der Achse) welche die Klassen gut separiert
 - Jede Region sollte möglichst nur Daten einer Klasse enthalten (Purity)




Vorhersagen mit Entscheidungsbaum

- Folge Baumstruktur bis zu entsprechendem Blatt
- Blatt bestimmt Klassifizierung



Klassifikation für Punkt
 $x^* = (\text{Fare}=25, \text{Age} = 30)$




Trainieren eines Entscheidungsbaums (informell)

Algorithmus (rekursiv, ausgehend von Wurzel)

1. Berechne Impurity für jeden möglichen Schnitt (jedes Merkmal und jeden Datenpunkt)
2. Wähle Schnitt, der grösste Reduktion der Impurity bewirkt (Information Gain)

Teile Knoten in Baum bis eine der Abbruchbedingungen erfüllt ist

- Anzahl Beispiele in Knoten klein ist
- Impurity unter einen gewissen Schwellwert fällt
- die maximale Tiefe des Baums erreicht wird



Mass für Impurity:

Entropie für Menge der Punkte an Knoten S

$$E(S) = -p_0 \log_2(p_0) - p_1 \log_2(p_1)$$

wobei p_0, p_1 die (geschätzte)

Wahrscheinlichkeit für die jeweilige Klasse ist

Trainieren von KNN und Decision Trees mit Scikit-learn

```
# Nearest Neighbor Klassifikator erstellen
```

```
knn_model = knn= KNeighborsClassifier(n_neighbors=10)
```

```
# Modell an die Daten anpassen (Merkmale X, Label y)
```

```
knn_model.fit(X, y)
```

```
# Vorhersage
```

```
y_pred = knn_model.predict(X)
```

```
# Decision tree erstellen
```

```
dt_model = DecisionTreeClassifier(max_depth=4, criterion='entropy', min_samples_leaf=10)
```

```
# Modell an die Daten anpassen (Merkmale X, Label y)
```

```
dt_model.fit(X, y)
```



```
# Vorhersage
```

```
y_pred = dt_model.predict(X)
```


Diskussion

Diskutieren Sie folgende Punkte:

- Können KNN und Decision Trees auch overfitten?
- Wie können Sie overfitting bei diesen Klassifikatoren verhindern?



KNNs und Decision Trees



Arbeiten mit nicht-numerischen Daten

Wie geht man mit nicht-numerischen und fehlenden Daten um?

Class	Sex	Age	Survived?
Crew	F	Adult	Y
Crew	F	Adult	-
First	M	Adult	N
First	M	Child	Y
Second	-	Adult	N
Second	M	Child	Y
Second	M	Adult	N

Fehlende Daten

Class	Sex	Age	Survived?
Crew	F	Adult	Y
Crew	F	Adult	-
First	M	Adult	N
First	M	Child	Y
Second	-	Adult	N
Second	M	Child	Y
Second	M	Adult	N

Löschen (einfach aber gefährlich)

- Zeile oder Spalte löschen
(Achtung: kann zu Datenverlust und Bias führen)

Imputation (ersetzen durch sinnvollen Wert)

- Statistisch
 - Häufigster Wert
 - Durchschnittswert
- Modellbasiert
 - Vorhersage durch ML Modell

Als eigene Kategorie behandeln


- Wert wird durch Platzhalter ersetzt ("Missing")

Beste Strategie ist abhängig von Problem, Bedeutung der Merkmale und der Daten

Ordinalzahl-Kodierung (Ordinal encoding)

Jeder Kategorie von nicht-numerischen Wert in Spalte wird eine eindeutige Zahl zugeordnet

Class	Sex	Age	Survived ?
Crew	F	Adult	Y
Crew	F	Adult	Y
First	M	Adult	N
First	M	Child	Y
Second	F	Adult	N
Second	M	Child	Y
Second	M	Adult	N



Class	Sex	Age	Survived ?
0	F	Adult	Y
0	F	Adult	Y
1	M	Adult	N
1	M	Child	Y
2	F	Adult	N
2	M	Child	Y
2	M	Adult	N

Ordinalzahl-Kodierung (Ordinal encoding)

Class	Sex	Age	Survived?
0	F	Adult	Y
0	F	Adult	Y
1	M	Adult	N
1	M	Child	Y
2	F	Adult	N
2	M	Child	Y
2	M	Adult	N

Vorteile:

- Einfach und effizient
- Eine Wert pro Kategorie


Nachteile

- Führt einen Begriff der Nähe ein, der falsch sein könnte.
 - Ist Crew (0) näher ans First (1) als Second (2)?

Zielvariablen Codierung (Target or mean encoding)

- Jede Kategorie wird durch Durchschnittswert der Zielvariable innerhalb dieser Kategorie ersetzt

Class	Sex	Age	Survived?
0	F	Adult	Y
0	F	Adult	Y
1	M	Adult	N
1	M	Child	Y
2	F	Adult	N
2	M	Child	Y
2	M	Adult	N




Class	Sex	Age	Survived?
0	F	0.4	Y
0	F	0.4	Y
1	M	0.4	N
1	M	1.0	Y
2	F	0.4	N
2	M	1.0	Y
2	M	0.4	N

Zielvariablen Codierung (Target or mean encoding)

Was ist die Codierung für Sex?

Class	Sex	Age	Survived?
0	F	Adult	Y
0	F	Adult	Y
1	M	Adult	N
1	M	Child	Y
2	F	Adult	N
2	M	Child	Y
2	M	Adult	N



Class	Sex	Age	Survived?
0		0.4	Y
0		0.4	Y
1		0.4	N
1		1.0	Y
2		0.4	N
2		1.0	Y
2		0.4	N

Zielvariablen Codierung (Target or mean encoding)

Class	Sex	Age	Survived?
0	0.66	0.4	Y
0	0.66	0.4	Y
1t	0.5	0.4	N
1	0.5	1.0	Y
2	0.66	0.4	N
2	0.5	1.0	Y
2	0.5	0.4	N

Vorteile

- Ein Wert pro Kategorie
- Die Codierung gibt dem Merkmal eine "Bedeutung": "Child" bedeutet, dass es mit Wahrscheinlichkeit 1 überlebt hat

Nachteile:

- Lässt Information aus den Features zu den Beispielen durchsickern. Kann zu overfitting führen.

One-hot encoding

Führt eine separate Spalte mit 0/1 Werten pro Kategorie ein - Immer ein Merkmal ist "Hot" (1)

Class	Sex	Age	Survived?
0	F	Adult	Y
0	F	Adult	Y
1	M	Adult	N
1	M	Child	Y
2	F	Adult	N
2	M	Child	Y
2	M	Adult	N

Class	Sex_M	Sex_F	Age	Survived?
0	0	1	Adult	Y
0	0	1	Adult	Y
1	1	0	Adult	N
1	1	0	Child	Y
2	0	1	Adult	N
2	1	0	Child	Y
2	1	0	Adult	N

One-hot encoding

Was ist die One-hot Codierung für folgende Daten:

Class	Sex	Age
Crew	F	Adult
First	M	Child
Second	F	Adult

Solution

Class Crew	Class First	Class Snd	Sex_M	Sex_F	Age Child	Age Adult
1	0	0	0	1	0	1
0	1	0	1	0	1	0
0	0	1	0	1	1	0

One-hot encoding

Class	Sex_M	Sex_F	Age	Survived?
0	0	1	Adult	Y
0	0	1	Adult	Y
1	1	0	Adult	N
1	1	0	Child	Y
2	0	1	Adult	N
2	1	0	Child	Y
2	1	0	Adult	N

Vorteile


- Alle Kategorien sind gleich weit voneinander entfernt
 - Keine Art von Nähe eingeführt

Nachteile:

- Führt zu grosse Anzahl Merkmale bei vielen Kategorien

Clustering

Erinnerung: Überwachtes Lernen (supervised learning)




Unüberwachtes Lernen (unsupervised learning)

Eingaben $x \in \mathbb{R}^d$

~~Supervisor~~

Fragen


- Können wir trotzdem aus Daten lernen?
- Was ist die Rolle des Modells?
- Was ist der Verlust und wie Optimieren wir diesen?



Zwei typische Beispiele für unsupervised learning


Dimensionalitätsreduktion

- Finde tiefer dimensionale Repräsentation der Daten




Clustering

- Identifiziere Gruppierungen in Daten




Struktur finden




- Welche Punkte gehören zusammen?
- Wie viele Gruppen sehen wir?

Struktur finden



- Welche Punkte gehören zusammen?
- Wie viele Gruppen sehen wir?


Struktur finden




- Welche Punkte gehören zusammen?
- Wie viele Gruppen sehen wir?

Diskussion


- Für welche realen Probleme oder Anwendungen (in der Physik / Wissenschaft oder im realen Leben) könnte es nützlich sein, ähnliche Gruppen in Daten zu finden?
- Wie wissen Sie, ob Sie die richtige Gruppierung gefunden haben?




Struktur finden



Wie die Daten generiert wurden






Ergebnis eines Algorithmus



Ergebnis eines anderen Algorithmus

- *Dem ersten Algorithmus wurde mitgegeben, dass es 3 Gruppen gibt (woher wissen wir das?)*

Struktur finden



Beobachtung

- Punkte derselben Gruppe sollten möglichst ähnliche Merkmale aufweisen (kleine Distanz im Merkmalsraum)
- Punkte in verschiedenen Gruppen sollten möglichst verschiedene Merkmale aufweisen


Achtung! Distanz hängt von Einheit ab - Standardisierung nötig

Das Clustering Problem: Konzeptionelle Übersicht

Gegeben: Menge von Punkten


Resultat:

- Mengen $C_1, \dots, C_K$ wobei jeder Punkte genau zu einer Menge gehört




Beispiele

$$C_1 = \{x_1, x_4, x_6\} \quad C_2 = \{x_2, x_3, x_5, x_7\}$$




$$C_1 = \{x_1, x_2, x_3, x_4\} \quad C_2 = \{x_5, x_6, x_7\}$$




Verlustfunktion

Verlust $L(C_k)$ solle für gute Clusterings klein sein.


- Mögliche Verlustfunktion:
Bestrafe Distanzen zwischen Punkten in demselben Cluster



$$C_1 = \{x_1, x_4, x_6\} \quad C_2 = \{x_2, x_3, x_5, x_7\}$$



$$C_1 = \{x_1, x_2, x_3, x_4\} \quad C_2 = \{x_5, x_6, x_7\}$$



K-Means clustering

Clustering als Optimierungsproblem

- Variabilität innerhalb eines Clusters $W(C_k)$

$$W(C_k) = \frac{1}{|C_k|} \sum_{x_i, x_j \in C_k} \text{dist}(x_i, x_j)$$

- Optimierungsproblem


$$\min_{C_1, \dots, C_K} \sum_{i=1}^K W(C_k)$$

Problem:

- Anzahl Mögliche Lösungen steigt exponentiell mit Anzahl Punkten.
- Diskretes Optimierungsproblem: Gradientenabstieg funktioniert nicht

Approximative Lösung

- Wähle k Zentroide
- Iteratives Minimieren der Abstände zum Zentroiden




K-Means

K-Means algorithmus


1. Wähle Anzahl Clusters K
2. Wähle zufällig K points als initiale Zentroiden

Wiederhole folgende Schritte bis Lösung konvergiert


3. Bestimme nächsten Zentroiden und weise Punkt entsprechendem Cluster zu
4. Bestimme neue Zentroiden als Schwerpunkt der Punkte im Cluster



Initialization



Iteration 1




Iteration 2

Eigenschaften

- Garantierte Konvergenz in endlicher Anzahl Schritten
- Findet nur lokales Minimum
- Quality der Lösung hängt von Initialisierung ab

K-Means – Initialization



Draw a point distribution:

1

2

3

4

5

6



Iterations: 1

3 clusters

General Statistics:

Delta position: 266.60

Animation: <https://user.ceng.metu.edu.tr/~akifakkus/courses/ceng574/k-means/>

K-means in Scikit-Learn



Zusammenfassung

Behandeln fehlender und nichtnumerischer Daten

- Daten kommen in Praxis meistens mit fehlenden Daten und nicht-numerischen Werten
- Verschiedene Techniken (Ordinal/Mean encoding, One-hot encoding) existieren um nicht-numerische Werte umzuwandeln und fehlende Werte zu wählen
 - Achtung: "Beste Lösung" hängt von Bedeutung der Daten ab

Überwachtes Lernen

- KNN und Decision trees sind nicht-parametrische Methoden für die Klassifikation
 - Machen keine Annahmen über Form der Lösung sondern lernen direkt Struktur der Daten

Clustering

- Beispiel für Nicht-überwachtes (unsupervised) learning
- Ziel: (Sinnvolle) Gruppierung in den Daten zu finden
 - Was sinnvoll ist hängt von Anwendung ab
- Beispielalgorithmus: K-Means Clustering.